

第 1 周学习报告：CS231n Assignment 1

WalkerZJH

2026.05.18 – 2026.05.24

1 任务背景与目标

本阶段围绕 CS231n Assignment 1 展开，主题包括 kNN、Softmax、SVM、TwoLayerNet、FullyConnectedNet、基础网络层、优化器和向量化实现。

本报告将 Assignment 1 的目标拆分为三类：

- **实现目标：**补全 kNN、Softmax、SVM、LinearClassifier、TwoLayerNet、FullyConnectedNet、常用 layer 和 optimizer。
- **验证目标：**通过 baseline 复现实验、训练曲线、准确率对比和小数据行为检查确认实现可以完整训练和预测。
- **探索目标：**围绕 kNN 的 k 值选择、线性分类器的学习率与正则、TwoLayerNet 的学习率/L2/batch size、初始化方式、优化器、归一化和 dropout 设计可复现实验。

当前代码、笔记和结果按公开归档结构保存：

- 过程代码：units/assignment1/code/;
- 实验设计：units/assignment1/experiments/;
- 学习笔记：units/assignment1/notes/;
- 实验结果：units/assignment1/results/;
- 阶段成果：deliverables/week01_assignment1/。

2 研究问题与探索路线

为了将报告从“完成记录”改为“问题驱动的实验记录”，本阶段围绕以下研究问题组织实现和实验。

编号	研究问题	验证方法	观察指标
RQ1	基础分类器和全连接网络是否能完成稳定训练与预测	baseline 复现实验、loss 曲线、准确率对比	train/val/test accuracy、final loss
RQ2	kNN 的 k 值如何影响验证集选择与测试表现	hard search 与 elbow 选择对比	val accuracy、test accuracy、选择的 k
RQ3	学习率、L2 正则和 batch size 如何影响训练动态	线性分类器与 TwoLayerNet 的控制变量搜索	loss 曲线、震荡/发散、train-val gap
RQ4	初始化、优化器、归一化和 dropout 如何影响优化与泛化	初始化消融、优化器消融、归一化/dropout 消融	收敛速度、验证准确率、泛化差距

表 1: Assignment 1 的研究问题与验证路线

3 框架设计与实现

3.1 整体代码架构

Assignment 1 的代码按功能拆分为四层：

- **数据层**：cs231n/data_utils.py 负责读取 CIFAR-10 并提供训练集、验证集和测试集划分。
- **基础算子层**：cs231n/layers.py 实现 affine、ReLU、normalization、dropout、convolution、pooling 和损失函数。
- **模型层**：cs231n/classifiers/ 实现 kNN、线性分类器、Softmax、SVM、TwoLayerNet 和 FullyConnectedNet。
- **训练与实验层**：solver.py、optim.py、run_assignment1_experiments.py 和 run_assignment1_exploration.py 负责训练、评估、结果保存和探索实验调度。

4 核心模块原理与实现要点

4.1 kNN

kNN 不显式学习参数，训练阶段保存训练样本，预测阶段计算测试样本到训练样本的距离并投票。无循环 L2 距离使用：

$$\|x - y\|_2^2 = \|x\|_2^2 + \|y\|_2^2 - 2x^\top y$$

该实现重点是将距离矩阵组织为 (num_test, num_train)，并在投票平票时选择较小标签以保证结果稳定。

4.2 Softmax 与 SVM

Softmax 使用线性 score 和交叉熵损失：

$$s = XW, \quad p_j = \frac{\exp(s_j)}{\sum_k \exp(s_k)}, \quad L = -\log p_y + \text{reg} \sum W^2$$

实现时先减去每个样本最大 score 以避免指数溢出。SVM 使用 multiclass hinge loss，关键是构造 margin 矩阵并对正确类别补回每行梯度的负计数。两者都提供 naive 与 vectorized 实现，用于理解循环版本和矩阵化版本之间的等价关系。

4.3 TwoLayerNet 与 FullyConnectedNet

TwoLayerNet 使用 affine-ReLU-affine-softmax 结构，是从线性分类器过渡到神经网络的最小例子。FullyConnectedNet 将该结构推广为多层网络，并可选使用 normalization 和 dropout。实现上每一层 forward 保存 cache，backward 按相反顺序传播梯度，L2 正则项以 $0.5 \cdot \text{reg} \sum W^2$ 写入损失，使梯度项为 $\text{reg}W$ 。

4.4 优化器

优化器模块实现 SGD、SGD with momentum、RMSProp 和 Adam。SGD 只使用当前梯度；momentum 维护速度项以平滑更新；Adam 同时维护一阶矩和二阶矩，并进行 bias correction。后续优化器消融用相同网络结构观察不同更新规则对 loss 曲线和验证准确率的影响。

5 实验设置

5.1 数据集与划分

实验使用 CIFAR-10 的完整训练设置：

- 训练集：49000 张；
- 验证集：1000 张；
- 测试集：10000 张；
- 运行环境：本地 Python 环境；
- kNN 使用完整训练集，距离计算采用 chunked 方式控制内存占用。

5.2 控制变量原则

探索实验按 suite 组织，每组只改变一个主要因素。例如 kNN 只改变 k ，TwoLayerNet 学习率搜索只改变 learning rate，初始化消融只改变初始化方式，优化器消融只改变 update rule。这样结果可以对应到具体训练机制。

6 超参数搜索与消融设计

6.1 kNN 的 k 值选择

kNN 实验比较 hard search 和 elbow 两种选择策略。hard search 直接选择验证准确率最高的 k ；elbow 在接近最高验证准确率的平台区间内选择较小 k ，用于观察模型选择是否对验证集细小波动过度敏感。

6.2 线性分类器学习率与正则搜索

Softmax 与 SVM 搜索 learning rate 和 L2 正则强度。学习率影响更新步长，L2 正则约束权重规模，两者共同决定 loss 下降速度、训练准确率和验证准确率。

6.3 TwoLayerNet 超参数搜索

TwoLayerNet 分别搜索学习率、L2 正则和 batch size。学习率实验用于观察发散和收敛速度；L2 实验用于观察欠拟合与过拟合；batch size 实验用于观察梯度噪声、训练耗时和泛化波动。

6.4 初始化、优化器与归一化消融

初始化消融比较 zero、normal 和 He 初始化；优化器消融比较 SGD、Momentum 和 Adam；归一化/dropout 消融比较无归一化、BatchNorm、LayerNorm 和 Dropout。该组实验用于解释训练动态差异，而不仅是选择最高准确率。

7 实验结果与分析

7.1 Baseline 结果

模型	设置	训练准确率	验证准确率	测试准确率
Softmax	lr= 10^{-7} , reg= 2.5×10^4 , iters=1500	0.3314	0.3460	0.3312
TwoLayerNet	momentum, lr=0.001, epochs=10	0.2204	0.2440	0.2218
FullyConnectedNet	Adam, lr=0.001, epochs=10	0.4670	0.4640	0.4360

表 2: Assignment 1 baseline 实验结果

baseline 中的 TwoLayerNet 使用固定 $lr = 10^{-3}$ 和 momentum 配置，loss 在后期放大到 10^{37} 量级。该曲线反映的是数值发散，不适合作为收敛曲线展示，因此报告中保留准确率对比图，并在学习率搜索部分用表格记录发散现象。




图 1: Assignment 1 baseline 验证集与测试集准确率对比

7.2 kNN 搜索结果

方法	选择的 k	验证准确率	测试准确率
hard search	1	0.3570	0.3513
elbow selection	1	0.3570	0.3513

表 3: kNN hard search 与 elbow 选择结果

两个选择策略都落在 $k = 1$ ，说明在完整训练集和当前验证集上，最近邻样本本身提供了最强的局部匹配信号。

7.3 线性分类器搜索结果

实验	选中配置	训练准确率	验证准确率	测试准确率
Softmax	$\text{lr}=10^{-7}, \text{reg}=10^4$	0.3546	0.3780	0.3523
SVM	$\text{lr}=10^{-7}, \text{reg}=10^4$	0.3842	0.3860	0.3760

表 4: Softmax 与 SVM 搜索结果

SVM 在完整训练设置下取得测试准确率 0.3760，优于 Softmax 的 0.3523。两者的最佳验证配置都使用较低正则强度 10^4 ，说明在完整训练集上，过强的 L2 约束会限制线性分类器的有效容量。

7.4 TwoLayerNet 搜索结果

实验	选中配置	训练准确率	验证准确率	测试准确率
学习率搜索	lr= 10^{-4}	0.5469	0.4920	0.4802
L2 正则搜索	reg= 10^{-3}	0.2299	0.2370	0.2401
batch size 搜索	batch size=128	0.2234	0.2400	0.2193

表 5: TwoLayerNet 超参数搜索结果

配置	学习率	数值状态	验证准确率	测试准确率
A1-HP-LR-001	10^{-2}	loss 溢出并出现 NaN	0.1670	0.1533
A1-HP-LR-002	10^{-3}	loss 放大到 10^{40} 量级	0.2280	0.2303
A1-HP-LR-003	10^{-4}	loss 稳定下降	0.4920	0.4802

表 6: TwoLayerNet 学习率搜索的数值稳定性

学习率搜索中, 10^{-2} 和 10^{-3} 都表现出明显的数值不稳定。前者在训练中出现溢出和 NaN, 后者虽然没有变成 NaN, 但 final loss 达到 10^{40} 量级, 已经不能作为稳定收敛的候选配置。可以看出, 学习率过大导致参数更新越过了 loss landscape 中的稳定区域, 造成训练震荡和发散。因此, 应合理选择学习率, 以充分利用短训练期内的快速迭代。

7.5 消融实验结果

实验	选中配置	训练准确率	验证准确率	测试准确率
初始化消融	He 初始化	0.2358	0.2520	0.2318
优化器消融	SGD	0.5489	0.4960	0.4855
归一化/dropout 消融	无归一化/无 Dropout	0.4777	0.4840	0.4637

表 7: Assignment 1 消融实验结果

优化器消融中, Momentum 在相同学习率下出现明显数值发散, loss 达到 10^{40} 量级。该现象更适合用表格和文字说明, 不作为收敛曲线插图。




图 2: 修正固定 dropout seed 后的归一化与 Dropout 消融损失曲线




图 3: 修正固定 dropout seed 后的归一化与 Dropout 消融准确率对比

初始化消融中，零初始化接近随机猜测，符合隐藏单元对称性无法有效破缺的预期。He 初始化 在固定 $lr = 10^{-3}$ 的 momentum 配置下验证准确率略高，但 final loss 偏大，说明初始化方式需要 和学习率共同判断。优化器消融中 SGD 取得最高验证和测试准确率，Momentum 在同一学习率下 发散，Adam 则稳定但测试准确率低于 SGD。归一化/dropout 消融中，无归一化且不使用 Dropout 的全连接网络表现最好；BatchNorm 和 LayerNorm 在当前浅层、短训练配置下没有带来提升。修 正固定 dropout seed 后，Dropout 单独使用的测试准确率为 0.4383，低于无 Dropout 对照，但旧结 果中的周期性 loss 尖峰已经消失。

8 问题、调试过程与解决方案

8.1 学习率发散现象

TwoLayerNet 学习率搜索中, $lr = 10^{-2}$ 出现溢出和 NaN, $lr = 10^{-3}$ 的 loss 也放大到 10^{40} 量级。这是学习率过大导致参数更新越过稳定区域的典型现象。解决方案是引入学习率衰减机制, 或者在搜索过程中增加更细粒度的学习率选项, 如 5×10^{-4} 、 2×10^{-4} 等, 以找到既能快速下降又不失稳定性的学习率。

9 阶段性总结与后续计划

9.1 模型理解方面的收获

kNN 体现了非参数方法中“训练简单、预测依赖全量距离计算”的特点; Softmax/SVM 体现了线性分类器在原始像素上的基本判别能力; TwoLayerNet 和 FullyConnectedNet 展示了非线性模型容量提升后对学习率、初始化、正则和优化器更敏感。

9.2 调优能力方面的收获

本阶段结果说明, 调参需要同时看 loss 曲线、验证准确率、测试准确率和 train-val gap。验证集用于选择配置, 测试集用于最终观察; 当测试表现与验证选择不完全一致时, 应优先维护验证集选择原则, 避免测试集泄漏到调参过程。