

Task1: NumPy 神经网络框架设计与实验

WalkerZJH

2026.06.15 – 2026.06.21

摘要

本阶段从零实现一个仅依赖 NumPy 完成模型计算和反向传播的轻量神经网络框架。框架覆盖全连接、卷积、BatchNorm、Dropout、池化、Softmax Cross Entropy 和常用优化器，并通过数值梯度、模式切换与 naive/vectorized 卷积一致性验证实现正确性。在完整 Digits 数据集上完成第一轮正式实验后，进一步在完整 CIFAR-10 上复用相同实验矩阵，对比不同数据复杂度下的模型、学习率及模块行为。实验配置只依据验证集选择，测试集仅用于选择后的最终观察。

1 任务目标与研究问题

Task1 的实现与 CS231n Assignment 代码相互独立，按核心库、训练器、配置、实验入口和结果归档组织。研究问题包括：手写 backward 是否正确；向量化卷积是否保持一致并提高效率；MLP、MLP+BN 与 CNN 的训练差异；学习率对收敛的影响；BatchNorm 与 Dropout 对拟合和泛化的影响。

2 数据集与实验协议

使用 scikit-learn 内置 Digits，共 1797 张 8×8 灰度图像。像素从 $[0, 16]$ 缩放到 $[0, 1]$ ，固定 seed 42 分层划分为训练 1257、验证 269、测试 271。scikit-learn 只负责加载内置数据和分层划分，模型计算与指标均由 NumPy 实现。

正式训练使用完整训练集。统一 baseline 为 hidden dimension 128 的 MLP、Adam、batch size 64、40 epochs、L2 正则 10^{-4} 。所有 suite 共享数据划分与 seed。按最高 validation accuracy 保存模型状态；test set 在配置选择完成后才计算。

为检验 Digits 接近饱和时结论的区分度，追加完整 CIFAR-10 对照实验。官方训练部分按 seed 42 分层划分为训练 45000、验证 5000，官方测试集保留 10000 张；图像为 $3 \times 32 \times 32$ ，像素缩放到 $[0, 1]$ 。CIFAR-10 沿用 40 epochs、batch size 64、Adam 和同一组模型与消融设置，模型参数采用 float32。配置选择和测试集使用规则与 Digits 一致。

3 框架设计与模块实现

3.1 模块和状态

`Parameter` 保存参数与梯度, `Module` 提供参数、train/eval 递归切换及状态字典。BatchNorm 的 running mean/variance 作为 buffer 一同保存, 使 best-validation 快照能够完整恢复推理状态。`Sequential` 负责顺序执行 forward, 并按逆序传播梯度。

3.2 核心计算

Linear 使用 $Y = XW + b$, 反向为 $dX = dYW^T$ 、 $dW = X^T dY$ 。ReLU 通过输入正值 mask 传递梯度。Softmax Cross Entropy 对 logits 做最大值平移, 并使用 $(p - \text{onehot}(y))/N$ 计算梯度。

卷积同时实现显式循环的 naive 版本和 im2col 版本。向量化 forward 将窗口矩阵与展平卷积核相乘; backward 使用 col2im 和 `np.add.at` 累加重叠位置梯度。BatchNorm 区分 batch statistics 与 running statistics; Dropout 使用 keep ratio 语义和实例级随机生成器, 避免污染 batch shuffle 的随机状态。

4 正确性与效率验证

表 1: 数值梯度检查最大相对误差

模块	dX	$dW/d\gamma$	$db/d\beta$
Linear	5.58×10^{-11}	1.69×10^{-10}	5.27×10^{-11}
BatchNorm	5.93×10^{-11}	1.54×10^{-11}	1.45×10^{-11}
Conv2D	8.97×10^{-9}	2.45×10^{-9}	5.57×10^{-11}

全部误差低于 10^{-6} 。naive/vectorized 卷积 forward、 dX 、 dW 、 db 的最大相对误差低于 10^{-14} 。当前固定 benchmark 中 naive forward 平均 0.2806 秒, vectorized 平均 0.0009 秒; 短计时存在波动, 量级上约为 300 倍加速。Dropout 和 BatchNorm 的 train/eval 行为检查均通过。

5 Digits Baseline

Digits 数据集下, MLP baseline 的训练 loss 从 1.9146 降至 0.0508, 第 40 个 epoch 的训练准确率为 0.9960、validation accuracy 为 0.9814。选择完成后, test accuracy 为 0.9815。




图 1: Digits 数据集下的 MLP baseline 训练曲线

6 Digits 模型对比

表 2: Digits 数据集下的模型对比（按各模型最高 validation accuracy 记录）

模型	参数量	最佳 epoch	训练 acc	验证 acc	时间/秒
MLP	9610	40	0.9960	0.9814	0.59
MLP+BN	9866	37	1.0000	0.9814	0.75
CNN	8986	39	0.9960	0.9777	2.62

Digits 数据集下, MLP+BN 的前期收敛更快, 并以 0.0869 的 validation loss 达到与 MLP 相同的最高准确率。CNN 在当前 8×8 输入和单卷积结构下未超过 MLP, NumPy 卷积训练耗时约为 MLP 的 4.4 倍。




图 2: Digits 数据集下 MLP、MLP+BN 与 CNN 的最佳验证准确率

7 Digits 学习率搜索

表 3: Digits 数据集下固定其他条件后的学习率搜索

学习率	最佳 epoch	训练 acc	验证 acc	验证 loss
0.0005	34	0.9753	0.9628	0.2053
0.0010	40	0.9960	0.9814	0.1166
0.0030	26	0.9992	0.9851	0.0936

Digits 数据集下，0.0005 在 40 epochs 内尚未充分收敛；0.003 更快进入高准确率区间且未发散。按 validation accuracy 选中 0.003 后，test accuracy 为 0.9815。




图 3: Digits 数据集下学习率搜索的最佳验证准确率

8 Digits BatchNorm / Dropout 消融

表 4: Digits 数据集下固定 seed 和训练设置后的模块消融

配置	最佳 epoch	训练 acc	验证 acc	验证 loss
Plain MLP	40	0.9960	0.9814	0.1166
+ BatchNorm	37	1.0000	0.9814	0.0869
+ Dropout ($q = 0.8$)	40	0.9928	0.9851	0.1208

Digits 数据集下，BatchNorm 改善收敛与 validation loss，但没有提高最高 accuracy。Dropout 降低训练准确率，并在验证集上多正确约一个样本；按验证集选中后，其 test accuracy 为 0.9742，

低于 baseline。269 张验证集的 accuracy 最小步长约为 0.0037，因此当前单次划分不足以证明 Dropout 稳定提升，需要多 seed 结果支持。实验仍保留既定选择，不依据 test 回退配置。




图 4: Digits 数据集下 BatchNorm / Dropout 消融的最佳验证准确率

9 完整 CIFAR-10 对照实验

9.1 Baseline 与模型对比

MLP baseline 在第 25 个 epoch 取得最高 validation accuracy 0.4648，此时训练准确率为 0.4880；完成验证集选择后，test accuracy 为 0.4627。相较于 Digits，CIFAR-10 上的准确率分布不再接近饱和，模型结构之间出现了更清晰的差异。




图 5: CIFAR-10 数据集下的 MLP baseline 训练曲线

CIFAR-10 MLP baseline 的训练与验证指标在前期同步改善，中后期验证 loss 和 accuracy 出现波动，训练集仍保持更高准确率。第 25 个 epoch 的 best-validation 快照避免了直接使用最后一

轮状态。

表 5: 完整 CIFAR-10 上的模型对比

模型	参数量	最佳 epoch	训练 acc	验证 acc	验证 loss
MLP	394634	25	0.4880	0.4648	1.5628
MLP+BN	394890	14	0.6278	0.5060	1.4301
CNN	132010	22	0.7403	0.6250	1.1306

CNN 以更少参数取得最高 validation accuracy 0.6250, 选中后的 test accuracy 为 0.6089。该结果与 Digits 上 CNN 未超过 MLP 的现象形成对照: 当输入扩大到彩色 32×32 图像后, 局部连接与权重共享带来的结构优势更容易体现。MLP+BN 也由 0.4648 提升至 0.5060, 说明归一化对当前 MLP 的优化具有实际影响。

CIFAR-10 - cnn Training Curves




图 6: CIFAR-10 数据集下验证集选中 CNN 的训练曲线

CIFAR-10 CNN 在约第 22 个 epoch 后训练 loss 继续下降、训练准确率继续上升, 但 validation loss 转为上升且 validation accuracy 维持在约 0.60 附近, 形成明确的泛化差距。因此表中的 CNN 指标来自第 22 个 epoch 的验证集最优状态, 而不是第 40 个 epoch。




图 7: 完整 CIFAR-10 上的模型最佳验证准确率

9.2 学习率搜索

表 6: 完整 CIFAR-10 上的 MLP 学习率搜索

学习率	最佳 epoch	训练 acc	验证 acc	验证 loss
0.0005	34	0.5487	0.4980	1.4517
0.0010	25	0.4880	0.4648	1.5628
0.0030	34	0.4328	0.4164	1.6549

验证集选择了 learning rate 0.0005, 选中后的 test accuracy 为 0.4931。Digits 上较优的 0.003 在 CIFAR-10 上反而最低, 说明学习率结论依赖数据分布、输入维度和损失地形, 不能直接跨数据集迁移。




图 8: 完整 CIFAR-10 上不同学习率的最佳验证准确率

9.3 BatchNorm / Dropout 消融

模块消融固定使用 baseline 训练设置，目的是比较模块影响；学习率搜索结果不与模块消融组合为新的配置。因此，表 7 中 Plain MLP 使用 learning rate 0.001，而不是学习率搜索选中的 0.0005。

表 7: 完整 CIFAR-10 上的模块消融

配置	最佳 epoch	训练 acc	验证 acc	验证 loss
Plain MLP	25	0.4880	0.4648	1.5628
+ BatchNorm	14	0.6278	0.5060	1.4301
+ Dropout ($q = 0.8$)	35	0.3900	0.3826	1.7310

BatchNorm 在验证准确率和 validation loss 上均优于 plain MLP，选中后的 test accuracy 为 0.5085。Dropout keep ratio 0.8 在当前 40-epoch 设置下同时降低训练与验证表现，表现为明显的优化不足；它没有复现 Digits 上单次划分中的轻微验证优势。当前结果只支持该配置在此训练预算下不合适，Dropout 强度和学习率仍需联合控制变量实验。




图 9: 完整 CIFAR-10 上的 BatchNorm / Dropout 消融

10 调试过程

实现过程中修正了配置层级读取和 CSV 字段一致性问题。第一次探索运行还发现不同 run 使用不同 seed 会破坏控制变量，因此该批结果被废弃；正式模型对比、学习率搜索和消融均在固定 seed 后重跑。Dropout 使用实例级 Generator，避免每次 forward 重置全局随机状态。

11 结论与后续

Task1 已形成可复现的 NumPy 框架和正式实验闭环。Digits 实验验证了实现正确性，但接近饱和的准确率限制了结构比较的区分度；在完整 CIFAR-10 对照实验中，CNN 明显优于 MLP，BatchNorm 改善 MLP，而学习率和 Dropout 结论不能从 Digits 直接迁移。后续适合补充多 seed 均值与标准差，并对 CNN 的通道数、学习率和正则强度做控制变量搜索。