

Task2: AG-News 分类模型设计、对比与分析

DL Foundations Lab

2026.06.22 – 2026.06.28

摘要

本任务围绕简单分类模型设计与实现，选择 AG-News 文本分类数据集进行实验。AG-News 数据规模适中、训练成本较低，因此用于完整比较 MLP/FN、FastText-style pooling、TextCNN、LSTM/BiLSTM、BiLSTM-Attention、RCNN、TransformerEncoder 与 DistilBERT。所有配置选择均基于 validation set，test set 仅作为最终观察。本轮结果显示，AG-News 上轻量 scratch 模型大多处于 91%–92% test accuracy 区间，DistilBERT fine-tuning 达到 94.66% test accuracy；概率平均 ensemble 达到 93.92% test accuracy，作为有效的模型互补性验证保留。

1 任务目标与研究问题

研究问题如下：RQ1，轻量模型是否能在 AG-News 上接近或超过参考 baseline；RQ2，更强文本结构、预训练表示和 ensemble 是否带来稳定收益；RQ3，scratch 模型的结构、训练成本和泛化行为有何差异；RQ4，validation 选择与 test observation 是否一致；RQ5，错误主要集中在哪些类别。

2 数据集与实验协议

2.1 AG-News

AG-News 使用 Hugging Face `ag_news`。官方 train/test 为 120000/7600；本实验从官方 train split 中按 label 分层切出 10% validation，seed=42，最终为 train=108000、validation=12000、test=7600。标签为 0 World、1 Sports、2 Business、3 Sci/Tech。

文本预处理采用 lowercase regex tokenizer，词表仅由 train split 构建，`<pad>`=0，`<unk>`=1。轻量模型默认 `vocab_size`=30000、`max_seq_len`=128；强化实验按配置扩展到 50000 词表或 256 长度。LSTM 系列通过 `pack_padded_sequence` 避免 padding 位置污染序列状态。

3 模型设计与实现

3.1 文本模型

MLP/FN 使用 masked mean pooling 后接两层全连接，用于验证主题词信号的强度。FastText-style 模型保留均值池化思路，但使用更大的 embedding 表达浅层 n-gram/词汇信号。TextCNN 使

用多 kernel 卷积:

$$h_k = \text{ReLU}(\text{Conv1d}_k(X)), \quad z_k = \max_t h_{k,t}, \quad y = W[z_2, z_3, z_4, z_5] + b.$$

LSTM/BiLSTM 使用门控序列状态;BiLSTM-Attention 对所有有效位置学习 attention 权重。RCNN 拼接 embedding 与 BiLSTM 上下文后做 max pooling。TransformerEncoder 从零训练两层自注意力编码器, 用于检验“无预训练自注意力”是否优于 TextCNN。DistilBERT fine-tuning 使用预训练 `distilbert-base-uncased`, 只提交指标和预测, 不提交模型权重。

4 正确性验证与工程检查

表 1: AG-News correctness checks

检查项	结果
split 数量与 label set	passed
tokenizer / label mapping	passed
padding / length mask	passed
single batch loss	1.7984 $\rightarrow$ 0.0007
train/eval dropout mode	passed

工程层面保留数据与 checkpoint 的忽略规则, AG-News CSV、HF cache、模型权重均不提交。DistilBERT 下载时出现 Windows symlink 降级提示, 但不影响模型加载和 fine-tuning。

5 AG-News 轻量基线实验

5.1 轻量基线实验设置

AG-News 轻量基线实验用于建立从零训练模型的可解释参照。所有轻量模型共享相同数据划分: 官方 train split 中按 label 分层切出 10% 作为 validation, seed=42; test set 仅用于最终 observation。文本侧统一使用 lowercase regex tokenizer, 词表仅由 train split 构建, `<pad>`=0、`<unk>`=1。除特别说明外, 轻量模型使用 `vocab_size=30000`、`max_seq_len=128`、`batch_size=128`、Adam 优化器、`learning_rate=1e-3`、`weight_decay=1e-4` 和 6 epoch 快速筛选预算。训练目标为 cross entropy; 配置选择标准为 validation accuracy, test set 只用于最终 observation。

表 2: AG-News lightweight suite 模型与用途

run	model	structure	purpose
baseline_textcnn	TextCNN	Embedding + Conv1D + max pooling	TextCNN baseline
hparam_dropout_0.2	TextCNN	same as baseline	regularization strength
model_mlp	MLP/FN	masked mean pooling + 2-layer MLP	word-level topic signal
model_bilstm	BiLSTM	packed bidirectional LSTM	sequence context

表 3: AG-News lightweight suite 训练配置

run	emb	hidden/filters	dropout	optimizer	lr	epochs
baseline_textcnn	128	filters=128	0.5	Adam	1e-3	6
hparam_dropout_0.2	128	filters=128	0.2	Adam	1e-3	6
model_mlp	128	hidden=256	0.5	Adam	1e-3	6
model_bilstm	128	hidden=128	0.5	Adam, clip=5.0	1e-3	6

TextCNN 的计算形式为

$$h_k = \text{ReLU}(\text{Conv1D}_k(X)), \quad z_k = \max_t h_{k,t}, \quad \hat{y} = W[z_3, z_4, z_5] + b.$$

不同 kernel size 分别捕捉不同长度的局部 n-gram 模式。MLP/FN 对非 padding token 的 embedding 做 masked mean pooling, 作为最简单的词级主题聚合模型。BiLSTM 通过双向门控状态建模上下文, 并用 `pack_padded_sequence` 避免 padding 位置污染序列状态。

5.2 轻量基线结果

表 4: AG-News lightweight suite 摘要

run	model	best epoch	best val acc	test acc
baseline_textcnn	TextCNN	6	0.9192	0.9149
hparam_dropout_0.2	TextCNN	6	0.9228	0.9167
model_mlp	MLP	6	0.9198	0.9121
model_bilstm	BiLSTM	5	0.9183	0.9163

轻量实验的主要结论不是某个 scratch 模型已经充分优化, 而是 AG-News 存在较强主题词信号: MLP/FN 通过均值池化已接近 TextCNN, 说明很多样本可以由词级主题特征区分。TextCNN 在 validation 上略优, 说明局部短语模式仍有价值; BiLSTM 的 test observation 接近 TextCNN, 但 validation 未形成稳定优势, 说明在 6 epoch 预算下序列模型尚未充分体现其上下文建模能力。

每个 epoch 的 `train_loss`、`train_acc`、`val_loss`、`val_acc` 和 `val_macro_f1` 已保存到各 run 的 `metrics.csv`。例如 `baseline_textcnn` 的 validation accuracy 从 epoch 1 的 0.8653 上升到 epoch 6 的 0.9192, `hparam_dropout_0.2` 从 0.8732 上升到 0.9228; 对应训练曲线用于检查训练是否持续收敛、是否出现明显过拟合以及最佳 epoch 是否发生在训练末端。

最优 lightweight validation run 是 `hparam_dropout_0.2`, 其 test observation 为 0.9167, 尚未稳定超过 92%。由于该 run 在第 6 epoch 仍达到最佳 validation, 6 epoch 更适合作为快速筛选预算, 而不是最终训练上限。后续强化实验因此不再只做小范围调参, 而是从训练预算、训练策略、模型结构和预训练表示四个方向继续验证。




图 1: AG-News lightweight validation accuracy, zoomed scale. The x-axis is truncated to 0.88–0.93 to show small validation differences.

图中横轴采用缩放范围，而不是默认 0–1 accuracy 范围，因此可以看出 `hparam_dropout_0.2` 相比 `baseline` 和其他轻量模型的细微优势。红色参考线表示 92% validation reference。该图只能说明同一 AG-News lightweight suite 内部的 validation 差异，不能把 0.1%–0.3% 的视觉差异解释为稳定统计优势；最终仍需要结合 test observation 和训练曲线。

6 AG-News 强化实验

6.1 强化实验设置

强化实验的目标是验证轻量 scratch 模型未稳定超过 92% 的原因：是训练预算不足、训练策略不足、模型结构表达不足，还是缺少预训练语言知识。为避免把多种因素混在一起解释，本节将强化实验分为四类：训练策略增强、scratch 架构增强、预训练模型 fine-tuning 和概率平均 ensemble。

表 5: AG-News strengthened suite 模型与改进点

label	model	source	improvement point
TextCNN+LS	TextCNN	scratch	label smoothing reduces over-confidence
BiLSTM20	BiLSTM	scratch	longer sequence-model training budget
FastText-style	lexical pooling	scratch	shallow lexical pooling signal
Transformer-s	TransformerEncoder	scratch	self-attention without pretraining
DistilBERT	DistilBERT	pretrained	contextual representation transfer
Ensemble	Probability average	no retraining	model complementarity

表 6: AG-News strengthened suite 训练配置

label	key config	optimizer / schedule	budget and cost	
TextCNN+LS	emb=128, filters=128, dropout=0.2, label smoothing=0.05	AdamW 1e-3, cosine warmup	20 planned;	13 ran; 162MB
BiLSTM20	emb=128, hidden=128, dropout=0.5, gradient clip=5.0	AdamW 1e-3	20 planned;	early stopped; 193MB
FastText-style	emb=200, masked mean pooling, dropout=0.2	AdamW 1e-3	20 planned;	early stopped; 158MB
Transformer-s	vocab=50000, len=256, layers=2, heads=4, ffn=512	AdamW 5e-4, cosine warmup	20 planned;	13 ran; 798MB
DistilBERT	distilbert-base-uncased, len=128, batch=32, fp16 on CUDA	AdamW 2e-5, linear warmup	3 planned;	3 ran; 1713MB
Ensemble	DistilBERT + TextCNN+LS + RCNN probability average	none	no training;	1713MB peak from members

DistilBERT fine-tuning 与 scratch 模型并不是完全公平的“纯架构对比”。TextCNN、FastText-style、BiLSTM、RCNN 和 TransformerEncoder 均从 AG-News train split 中学习任务表示；DistilBERT 则从 `distilbert-base-uncased` 初始化，已经携带大规模英文语料中的词义、句法和上下文知识。因此，DistilBERT 的提升应解释为预训练语言表示迁移带来的收益，而不是单纯“层数更深”或“结构更复杂”带来的收益。

6.2 强化实验结果

表 7: AG-News strengthened and pretrained results

run	model	best epoch	best val acc	test acc
ag_distilbert_finetune	DistilBERT	3	0.9483	0.9466
ag_textcnn_label_smoothing	TextCNN	8	0.9219	0.9186
ag_bilstm_20ep	BiLSTM	3	0.9173	0.9184
ag_fasttext_bigram	FastText-style pooling	8	0.9191	0.9154
ag_rcnn	RCNN	6	0.9203	0.9117
ag_transformer_encoder_small	TransformerEncoder	8	0.9148	0.9128
ag_ensemble_top3	Probability average	-	0.9483	0.9392

结果显示，scratch 结构增强没有稳定突破 92% test accuracy。TextCNN label smoothing 略高于初始 baseline，但提升有限；BiLSTM 延长训练后 test observation 达到 0.9184，但 validation 仍低于最优 lightweight run；FastText-style 接近 MLP/TextCNN，进一步支持 AG-News 中主题词和短语信号很强；从零训练的 TransformerEncoder 未超过 TextCNN，说明自注意力结构本身并不自动带来收益，尤其在大规模预训练和更长训练预算时，其优势并不稳定。

每个强化 run 同样保存逐 epoch 指标。以 `ag_textcnn_label_smoothing` 为例，validation accuracy 从 epoch 1 的 0.8426 上升到 epoch 8 的 0.9219，之后未继续改善并触发 early stopping；`ag_transformer_encoder_small` 从 epoch 1 的 0.8373 上升到 epoch 8 的 0.9148，但后续在 0.91–0.915 附近波动。DistilBERT 3 个 epoch 的 validation accuracy 分别为 0.9416、0.9458、0.9483，训

练准确率从 0.9005 上升到 0.9687，说明预训练模型在较短 fine-tuning 预算内已快速收敛。

DistilBERT fine-tuning 达到 0.9483 validation accuracy 和 0.9466 test accuracy，是本轮 AG-News 的最终最优模型。该结果说明主要提升来自预训练上下文表示。相比 scratch 模型，DistilBERT 更能区分公司、产品、市场、软件和硬件等语义边界模糊的新闻类别，尤其缓解 Business 与 Sci/Tech 的混淆。




图 2: AG-News strengthened model comparison on validation set. The axis is zoomed because all runs exceed 0.90 accuracy; black diamonds mark test accuracy.

该图将 scratch、pretrained 和 ensemble 用不同颜色区分，并同时标出 validation 与 test accuracy。它支持的结论是：DistilBERT 在 validation/test 上均领先，ensemble 已明显超过 92% reference 但低于 DistilBERT 单模；scratch 模型集中在 0.915–0.922 validation 区间。

表 8: Best scratch model and pretrained model on AG-News

category	selected run	val acc	test acc
Validation-selected scratch / lightweight	hparam_dropout_0.2	0.9228	0.9167
Best scratch test observation	ag_textcnn_label_smoothing	0.9219	0.9186
Pretrained fine-tuning	ag_distilbert_finetune	0.9483	0.9466

它是说明引入大规模语料预训练表示后，AG-News 分类性能明显提升。scratch 模型内部仍按 validation set 做配置选择。

7 AG-News 训练成本与泛化分析




图 3: DistilBERT train/validation accuracy curve

DistilBERT 的 validation accuracy 在 3 个 epoch 中从 0.9416 上升到 0.9483, best validation 出现在 epoch 3; train accuracy 同期从 0.9005 上升到 0.9687。该曲线说明预训练模型在短 fine-tuning 预算内快速适配 AG-News, 但 train-validation 差距也在扩大。因此 3 epoch 是合理的核心实验预算: 继续训练可能提高训练集拟合, 却不保证 validation/test 同步提升。

表 9: AG-News representative training cost

run	params	mean epoch time	total time	peak memory / test acc
baseline_textcnn	4.04M	10.3s	61.6s	162MB / 0.9149
hparam_dropout_0.2	4.04M	11.5s	69.1s	162MB / 0.9167
ag_textcnn_label_smoothing	4.04M	12.6s	164.2s	162MB / 0.9186
ag_rcnn	4.20M	48.4s	532.1s	289MB / 0.9117
ag_transformer_encoder_small	5.99M	66.8s	869.0s	798MB / 0.9128
ag_distilbert_finetune	66.96M	402.9s	1208.8s	1713MB / 0.9466

训练成本表说明, TextCNN 系列在 8GB RTX 4060 Laptop 上属于低成本实验, 单 epoch 约 10–13 秒; RCNN 和 scratch Transformer 明显更慢, 但没有带来对应的 accuracy 改善。DistilBERT 的参数量和单 epoch 时间最高, 不过 3 epoch 总时间仍在约 20 分钟量级, 峰值显存 1713MB, 符合本任务 24 小时复现实验预算。该表支持的结论是: 成本增加本身不是充分条件, 预训练表示迁移才是本轮 AG-News 性能跃升的主要原因。




图 4: AG-News train-validation gap at best validation epoch

train-val gap 定义为 best validation epoch 上的 $\text{train_acc} - \text{val_acc}$ 。当前多数模型 gap 约 0.02–0.06, 不能简单称为严重过拟合; 更准确地说, 部分模型出现轻度到中度 train-validation gap。较大的 gap 表明模型继续拟合训练集但验证集提升有限, 较小的 gap 表明训练更稳定, 但也可能意味着模型容量或训练预算不足。该图的价值不在于证明某个模型绝对过拟合, 而在于与 test accuracy、模型容量、训练时间一起判断泛化行为。




图 5: AG-News scratch models: parameter count vs test accuracy. DistilBERT is excluded from this linear parameter-axis plot.

该图只比较 scratch / lightweight / strengthened non-pretrained 模型, 避免 DistilBERT 约 66.96M 参数把线性横轴压缩到失去可读性。在 scratch 模型内部, 参数量增加并不必然带来更高 test accuracy。例如 TransformerEncoder from scratch 参数量高于部分轻量模型, 但没有超过 TextCNN, 说明在 AG-News 上, 预训练知识比简单扩大 scratch 模型更关键。DistilBERT 参数量约 66.96M, 峰值显存约 1713MB, 但它应作为预训练表示增强结果单独报告, 不与 scratch 模型放在线性参数

图中比较。

8 AG-News 错误分析

表 10: DistilBERT per-class metrics

class	precision	recall	F1
World	0.9602	0.9532	0.9567
Sports	0.9879	0.9863	0.9871
Business	0.9252	0.9116	0.9183
Sci/Tech	0.9136	0.9353	0.9243

Sports 是最容易的类别，原因是实体、赛事和词汇边界清晰。Business 与 Sci/Tech 仍是主要难点，因为公司、产品、市场、软件和硬件新闻存在大量语义交叉。DistilBERT 明显降低了混淆，但没有消除这一边界问题。




图 6: AG-News best model confusion matrix

混淆矩阵显示 Sports 类最稳定，主要错误集中在 Business 与 Sci/Tech 的相互混淆。这支持了前文的类别解释：体育新闻实体和事件边界清晰，而商业、公司产品、技术发布和市场新闻存在语义重叠。该图只反映最终 DistilBERT 模型的错误分布，不应外推为所有模型的错误模式完全一致。




图 7: AG-News per-class F1

per-class F1 进一步说明类别难度不均衡: Sports 明显最高, Business 与 Sci/Tech 较低。由于 AG-News test split 每类样本数相同, 这里的差异主要来自类别语义边界, 而不是类别频率失衡。该图不能说明模型对所有 Business/Sci-Tech 样本都失败, 只能说明这两个类别的平均边界更难。




图 8: Business/Sci-Tech confusion before and after pretraining

Business/Sci-Tech 专项图比较 lightweight best 与 DistilBERT 的互相混淆数量。DistilBERT 降低了该混淆, 但没有完全消除, 说明预训练上下文表示可以缓解语义边界问题, 却不能把公司、产品、软件、市场这类天然交叉的新闻语义完全分开。

9 结论与后续

AG-News 方向最终选择 `ag_distilbert_finetune`, validation accuracy 为 0.9483, test observation accuracy 为 0.9466, 超过 92% 目标。scratch 文本模型提供了结构对比和错误来源解释, 但未稳定突破 92%。